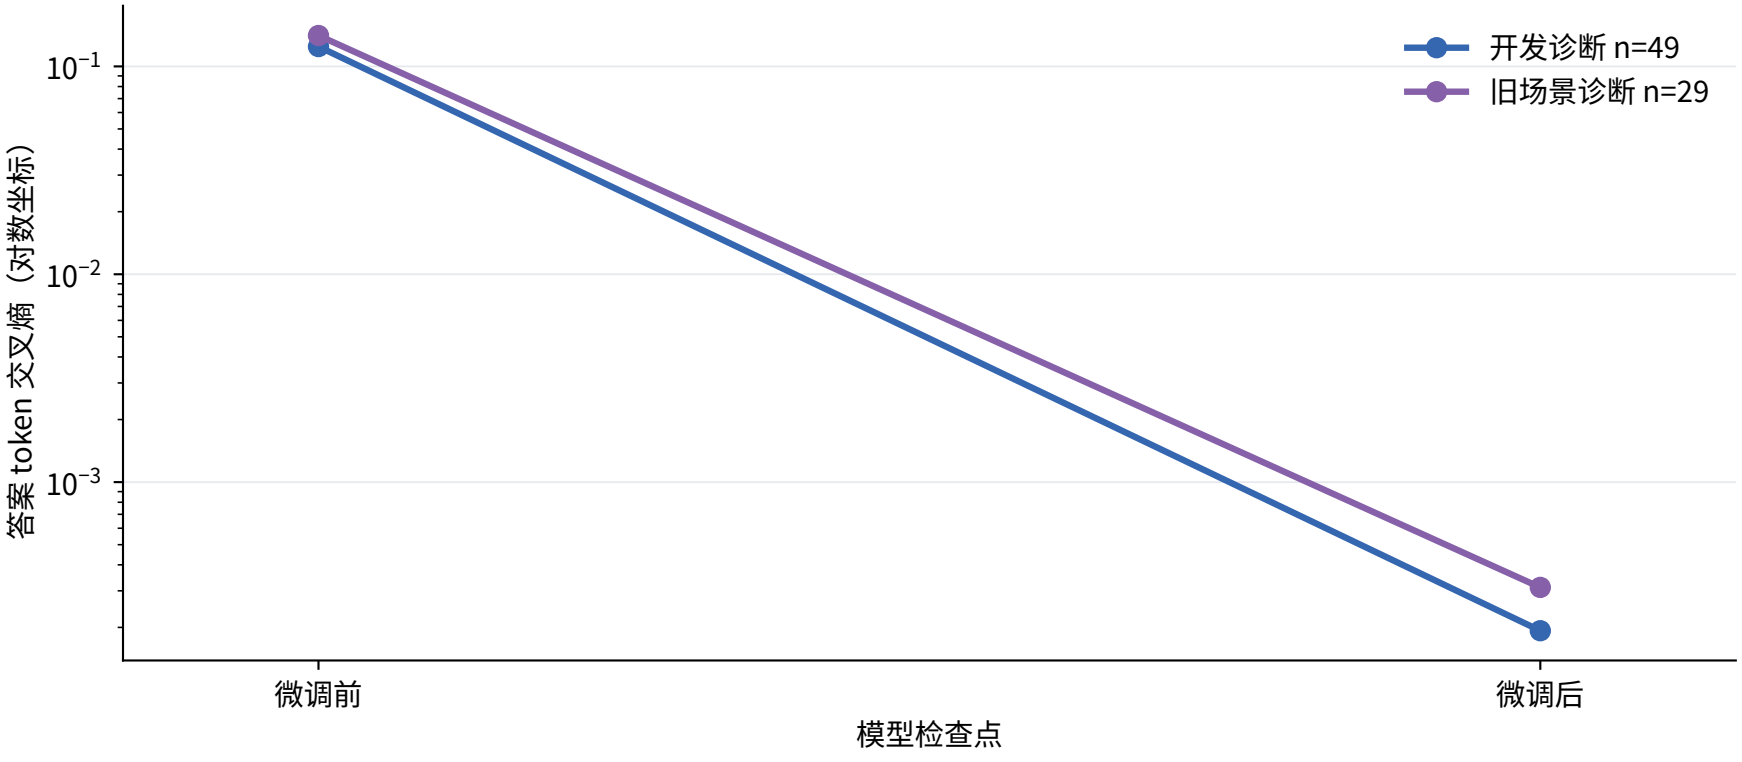
验证 loss 下降，但不等于任务准确率提高

159条训练版本；仅训练前后两个检查点，没有虚构中间验证轨迹



筛选后的开发子集；非最终测试。物理效果须看完整闭环任务，不能由loss替代。